Latar kuning = [ISI] yang diisi setelah eksperimen, atau angka dummy bertanda † (bukan hasil). **Kotak abu-abu** = penjelasan untuk Anda; hapus sebelum submit.

**CATATAN — hapus sebelum submit: Cara memakai dokumen ini**

Dokumen ini melanjutkan Bab I–III versi Bahasa Indonesia. TABEL I–III sudah dipakai di Metodologi, sehingga Hasil dimulai dari TABEL IV; Gambar 1 dan 2 sudah dipakai, sehingga gambar Hasil dimulai dari Gambar 3.

Teks di luar kotak adalah naskah paper dalam Bahasa Indonesia (angka ditulis [ISI]). Kotak abu-abu adalah panduan. Istilah teknis tetap dalam bahasa Inggris dan dicetak miring agar konsisten dengan literatur.

Keputusan yang dipakai: uji Wilcoxon signed-rank (bukan Mann–Whitney), R = 10, budget 600 s per modul untuk semua tool, B1 = proprietary, B2 = open-weight, MuTAP hanya di MT, RQ3 hanya di CM. Validitas tes diukur pada usulan mentah LLM (raw validity), bukan pada suite akhir. RQ2 tidak lagi mengklaim efek adaptasi prompt.

Referensi baru melanjutkan nomor Methodology: [27] Wilcoxon, [28] Spearman, [29] mixed-effects (lme4), [30] flaky test. Semua sumber [23]–[30] sudah dicek ke data bibliografi (13 Oktober 2026); daftarnya ada di akhir dokumen.

# IV. Hasil

Bagian ini menjawab ketiga pertanyaan penelitian secara berurutan. Kecuali dinyatakan lain, setiap nilai adalah median atas fungsi (MT) atau modul (CM) dari median per unit atas R = [ISI] *run* sebuah konfigurasi.

**CATATAN — hapus sebelum submit: Kenapa "median dari median"**

Setiap fungsi/modul dijalankan R kali per konfigurasi. Langkah 1: ambil median R run untuk setiap unit (satu angka per unit). Langkah 2: ambil median dari semua unit (satu angka per konfigurasi). Median dipakai karena tidak terpengaruh satu run yang gagal total. Cara ini mengikuti pelaporan per-modul di [10].

## *A. RQ1: Efektivitas Tool*

TABEL IV merangkum efektivitas setiap generator dan *backbone* pada kedua *suite*. Pada MT *suite*, *coverage* mencapai [ISI], sedangkan *mutation score* berkisar dari [ISI] sampai [ISI]. Sebelum diperbaiki oleh *tool*, [ISI]% tes yang diusulkan LLM valid. Pada CM *suite*, [ISI]. TABEL V menguji perbedaan berpasangan dengan *backbone* B1, dan Gambar 3 menunjukkan distribusinya pada MT *suite*.

**TABEL IV. Efektivitas generator (median atas unit)**

| Suite | Tool | BB | RV (%) | Flaky | LC (%) | BC (%) | MS (%) |
|---|---|---|---|---|---|---|---|
| MT | Pynguin | – | n/a | 0† | 95.2† | 93.0† | 53.1† |
| MT | CodaMOSA | B1 | – | – | – | – | – |
| MT | CodaMOSA | B2 | – | – | – | – | – |
| MT | CoverUp | B1 | – | – | – | – | – |
| MT | CoverUp | B2 | – | – | – | – | – |
| MT | MuTAP | B1 | 61.3† | 2† | 99.0† | 98.5† | 80.6† |
| MT | MuTAP | B2 | – | – | – | – | – |
| CM | Pynguin | – | n/a | – | – | – | – |
| CM | CodaMOSA | B1 | – | – | – | – | – |
| CM | CodaMOSA | B2 | – | – | – | – | – |
| CM | CoverUp | B1 | – | – | – | – | – |
| CM | CoverUp | B2 | – | – | – | – | – |

*BB = backbone; RV = raw validity, yaitu proporsi tes usulan LLM yang lulus pada kode yang tidak dimodifikasi sebelum diperbaiki oleh tool (n/a untuk Pynguin); Flaky = jumlah tes flaky dalam suite akhir; LC, BC = line dan branch coverage; MS = mutation score. LC, BC, dan MS dihitung pada tes valid. Pass rate suite akhir, yang mendekati 100% karena cara kerja tool, dilaporkan di paket replikasi. † Nilai dummy, hanya ilustrasi.*

**CATATAN — hapus sebelum submit: TABEL IV — arti kolom dan cara membaca**

**Letak:** Subbab IV-A (RQ1). **Sumber data:** S3 (status tes) dan S4 (perhitungan metrik) pada Gambar 1. **Analisis:** Analisis 1 (median) — deskriptif, belum ada uji signifikansi.

- **Suite / Tool / BB:** benchmark, generator, dan backbone. Pynguin bertanda "–" karena tidak memakai LLM. MuTAP hanya ada di baris MT.
- **RV (raw validity):** persentase tes yang DIUSULKAN LLM yang lulus pada kode asli, SEBELUM tool memperbaiki atau membuangnya. Diambil dari log llm_proxy. Pynguin tidak punya usulan LLM, sehingga n/a. Pass rate suite akhir tidak dipakai di tabel karena hampir pasti 100%: CoverUp hanya menyimpan tes yang lulus [10], MuTAP mengganti nilai harapan yang salah [11], Pynguin/CodaMOSA membuat assertion dari keluaran nyata. Preseden ukuran pada output mentah: CodaMOSA (persentase pernyataan LLM yang bisa di-parse) [9] dan MuTAP (syntax/assertion error rate) [11].
- **Flaky:** jumlah tes yang hasilnya berubah-ubah saat dijalankan ulang [30]. Idealnya 0.
- **LC / BC:** line dan branch coverage dari tes valid (coverage.py). Di MT diperkirakan mendekati 100% untuk semua tool (efek plafon, lihat [10]).
- **MS:** mutation score dari tes valid, dengan himpunan mutan yang sama untuk semua tool [25]. Ini pembeda utama di MT.

**Cara membaca:** bandingkan per kolom, bukan per baris. Tool terbaik di LC belum tentu terbaik di MS. RV yang rendah berarti tool sangat bergantung pada perbaikan internalnya. Selisih kecil (misalnya 98,5 vs 99,0) belum tentu nyata; signifikansinya dilihat di TABEL V.

**Contoh kalimat:** "*Coverage* pada MT *suite* mendekati plafon untuk semua generator, sedangkan MuTAP (B1) mencapai median *mutation score* tertinggi (80,6%)."

**TABEL V. Perbandingan berpasangan dengan backbone B1 (uji Wilcoxon signed-rank, koreksi Holm)**

| Suite | Metrik | A vs B | M/S/K | Â12 | p (Holm) |
|---|---|---|---|---|---|
| MT | MS | MuTAP vs Pynguin | – | – | – |
| MT | MS | MuTAP vs CodaMOSA | – | – | – |
| MT | MS | MuTAP vs CoverUp | 163/0/0† | 0.86† | <0.001† |
| MT | MS | CoverUp vs Pynguin | – | – | – |
| MT | MS | CoverUp vs CodaMOSA | – | – | – |
| MT | MS | CodaMOSA vs Pynguin | – | – | – |
| CM | BC | CoverUp vs Pynguin | – | – | – |
| CM | BC | CoverUp vs CodaMOSA | – | – | – |
| CM | BC | CodaMOSA vs Pynguin | – | – | – |
| CM | MS | CoverUp vs Pynguin | – | – | – |
| CM | MS | CoverUp vs CodaMOSA | – | – | – |
| CM | MS | CodaMOSA vs Pynguin | – | – | – |

*M/S/K = jumlah unit tempat A lebih tinggi, setara, atau lebih rendah daripada B; Â12 = peluang A mengungguli B (0,5 = tidak berbeda). p-value dikoreksi dengan metode Holm atas dua belas uji. Perbandingan untuk backbone B2 dan metrik lainnya ada di paket replikasi. † Nilai dummy.*

**CATATAN — hapus sebelum submit: TABEL V — arti kolom dan cara membaca**

**Letak:** Subbab IV-A (RQ1). **Sumber data:** median per unit dari TABEL IV (S4). **Analisis:** 2 (Wilcoxon signed-rank [27]), 3 (Â12 [24]), 4 (koreksi Holm [26]); pemilihan uji dan ukuran efek mengikuti pedoman Arcuri dan Briand [23].

- **Metric:** di MT hanya MS, karena coverage di MT terkena efek plafon. Di CM dipakai BC (lebih ketat daripada LC) dan MS, karena RQ1 menanyakan mutation score untuk semua tool. Metrik lain dan backbone B2 dipindah ke paket replikasi agar tabel muat.
- **A vs B:** pasangan tool dengan backbone yang sama (B1). MT 6 pasangan + CM 3 pasangan × 2 metrik = 12 uji.
- **M/S/K:** jumlah fungsi/modul tempat A menang/seri/kalah. Format ini meniru cara CodaMOSA melaporkan hasil (173 modul lebih baik, 10 lebih buruk).
- **Â12:** besar efek. 0,5 = setara; ≥ 0,56 kecil; ≥ 0,64 sedang; ≥ 0,71 besar [24]. Di bawah 0,5 berarti B yang unggul.
- **p (Holm):** p-value setelah koreksi Holm atas 12 uji. < 0,05 = perbedaan nyata.

**Kenapa Wilcoxon, bukan Mann–Whitney:** data berpasangan — setiap fungsi/modul dikerjakan oleh kedua tool — sehingga uji berpasangan lebih tepat dan jumlah uji kecil (12), sehingga Holm tidak terlalu ketat. Preseden: TestPilot [4] memakai Wilcoxon berpasangan untuk membandingkan LLM; Pynguin [7] dan CodaMOSA [9] memakai uji non-parametrik per modul.

**Contoh kalimat:** "MuTAP (B1) mencapai *mutation score* lebih tinggi daripada CoverUp (B1) pada seluruh 163 fungsi (Â12 = 0,86; *p* terkoreksi Holm < 0,001)."

**Gambar 3 — placeholder (boxplot, dua panel)**
Panel (a): line+branch coverage (%) · Panel (b): mutation score (%)
Sumbu-x: 7 konfigurasi MT (Pynguin, CodaMOSA-B1/B2, CoverUp-B1/B2, MuTAP-B1/B2)
Sumbu-y: persentase · satu titik data = median R run untuk satu fungsi

Gambar 3. Distribusi coverage per fungsi (a) dan mutation score (b) pada MT suite.

**CATATAN — hapus sebelum submit: Gambar 3 — fungsi gambar**

**Letak:** Subbab IV-A. **Analisis:** 1 (boxplot). Gambar ini memperlihatkan argumen inti paper: di MT panel coverage menempel di dekat 100% untuk semua tool, sedangkan panel mutation score terpisah jelas. Contoh gambar dengan data simulasi: boxplot_mt_simulasi.png.

### *B. RQ2: Algoritma dan Backbone*

TABEL VI melaporkan, untuk setiap generator berbasis LLM, perubahan efektivitas ketika *backbone* B1 diganti dengan B2; jenis adaptasi *prompt* yang dibutuhkan setiap generator dicantumkan sebagai informasi. TABEL VII melaporkan model *mixed-effects* beserta porsi variasi yang dijelaskan setiap faktor, dan Gambar 4 memvisualisasikan interaksinya. [ISI: kalimat temuan utama, mis. generator mana yang paling sensitif terhadap backbone].

**TABEL VI. Efek backbone pada setiap generator berbasis LLM (rata-rata atas unit)**

| Suite | Metrik | Tool | Adaptasi | B1 | B2 | Δ (B1−B2) |
|---|---|---|---|---|---|---|
| MT | MS | CodaMOSA | interface-only | – | – | – |
| MT | MS | CoverUp | tidak ada | – | – | – |
| MT | MS | MuTAP | [ISI] | 80.3† | 66.2† | 14.1† |
| CM | BC | CodaMOSA | interface-only | – | – | – |
| CM | BC | CoverUp | tidak ada | – | – | – |

*Adaptasi = jenis perubahan yang diperlukan agar generator dapat dijalankan dengan backbone masa kini (Bagian III-C). Δ = penurunan ketika B1 diganti dengan B2. † Nilai dummy.*

**CATATAN — hapus sebelum submit: TABEL VI — arti kolom dan cara membaca**

**Letak:** Subbab IV-B (RQ2). **Sumber data:** S4 + catatan adaptasi prompt dari S2 (docs/prompt_adaptations.md). **Analisis:** deskriptif (rata-rata per sel); uji signifikansinya ada di TABEL VII.

- **Adaptation:** interface-only = hanya format permintaan yang diubah (CodaMOSA: payload completions → chat); none = cukup ganti konfigurasi (CoverUp); content-changing = isi prompt ikut berubah. Jenis untuk MuTAP masih [ISI] di protokol. Kolom ini hanya INFORMASI: adaptasi sama untuk B1 dan B2 dalam satu tool, sehingga efeknya tidak bisa dipisahkan dari efek tool. Karena itu RQ2 direvisi dan tidak lagi mengklaim efek adaptasi; hal ini dibahas di Ancaman terhadap Validitas.
- **B1 / B2:** rata-rata metrik dengan masing-masing backbone. Rata-rata (bukan median) dipakai agar konsisten dengan model di TABEL VII.
- **Δ:** penurunan saat backbone diganti. Δ besar = generator sensitif terhadap backbone.

**Contoh kalimat:** "MuTAP adalah generator yang paling sensitif terhadap *backbone*: mengganti B1 dengan B2 menurunkan *mutation score*-nya sebesar 14,1 poin."

**TABEL VII. Model linear mixed-effects: metrik ~ tool × backbone + (1 | unit)**

| Suite | Metrik | Faktor | Estimasi | SK 95% | p | Var. (%) |
|---|---|---|---|---|---|---|
| MT | MS | Tool: CoverUp | – | – | – | – |
| MT | MS | Tool: MuTAP | – | – | – | – |
| MT | MS | Backbone: B2 | – | – | – | – |
| MT | MS | CoverUp × B2 | – | – | – | – |
| MT | MS | MuTAP × B2 | −13.1† | [−14.3, −11.9]† | <0.001† | 4.7† |
| CM | BC | Tool: CoverUp | – | – | – | – |
| CM | BC | Backbone: B2 | – | – | – | – |
| CM | BC | CoverUp × B2 | – | – | – | – |

*Kondisi acuan: CodaMOSA dengan B1. Estimasi dalam poin persentase; unit (fungsi atau modul) sebagai random intercept. SK = selang kepercayaan; Var. = porsi variasi yang dijelaskan oleh faktor tersebut. Analisis sensitivitas berbasis peringkat ada di paket replikasi. † Nilai dummy.*

**CATATAN — hapus sebelum submit: TABEL VII — arti kolom dan cara membaca**

**Letak:** Subbab IV-B (RQ2). **Sumber data:** semua run tool LLM dari S4 (bukan median). **Analisis:** 5 (linear mixed-effects model [29]; implementasi Python: statsmodels MixedLM, atau lme4 di R).

- **Faktor:** faktor yang diuji. "Tool" = efek algoritma; "Backbone" = efek model; "× B2" = interaksi (apakah efek backbone berbeda antar-tool).
- **Estimasi:** selisih dalam poin persentase terhadap kondisi acuan (CodaMOSA + B1). PENTING: karena memakai kondisi acuan, baris "Backbone: B2" adalah efek ganti backbone untuk CodaMOSA saja; baris "MuTAP × B2" adalah penurunan TAMBAHAN yang dialami MuTAP. Contoh dummy: CodaMOSA turun 1,0; MuTAP turun 1,0 + 13,1 = 14,1 poin (cocok dengan Δ di TABEL VI).
- **SK 95%:** selang kepercayaan, yaitu rentang ketidakpastian. Bila tidak melewati 0, efeknya nyata.
- **p:** signifikansi. Interaksi yang signifikan adalah temuan kunci RQ2: keunggulan sebuah algoritma bergantung pada backbone.
- **Var. (%):** porsi variasi metrik yang dijelaskan oleh faktor tersebut. Kolom ini yang menjawab frasa "seberapa besar … dapat diatribusikan" di RQ2. Contoh dummy: interaksi menjelaskan 4,7% variasi.
- **Analisis sensitivitas:** model diulang pada data yang diubah ke peringkat, karena skor dibatasi 0–100 dan bisa menumpuk di plafon. Bila kesimpulannya sama, hasil lebih meyakinkan.
- **(1 | unit):** fungsi/modul sebagai efek acak, supaya perbedaan tingkat kesulitan kode tidak dikira efek tool.

**Contoh kalimat:** "Interaksi *tool* × *backbone* signifikan pada MT *suite*: dengan B2, MuTAP kehilangan 13,1 poin lebih banyak daripada CodaMOSA (SK 95% [−14,3; −11,9])."

**Gambar 4 — placeholder (interaction plot)**
Sumbu-x: backbone (B1, B2) · Sumbu-y: mutation score (MT) atau branch coverage (CM)
Satu garis per generator LLM (CodaMOSA, CoverUp, MuTAP); titik = rata-rata, garis galat = 95% CI
Garis yang tidak sejajar = ada interaksi tool × backbone

Gambar 4. Rata-rata efektivitas generator berbasis LLM dengan backbone B1 dan B2.

**CATATAN — hapus sebelum submit: Gambar 4 — fungsi gambar**

**Letak:** Subbab IV-B. Gambar ini adalah cara paling mudah bagi reviewer untuk melihat interaksi: kalau garis MuTAP turun tajam sedangkan garis CodaMOSA hampir datar, efek backbone bergantung pada tool. Angkanya sama dengan TABEL VI.

### *C. RQ3: Karakteristik Kode*

TABEL VIII menghubungkan keunggulan per modul setiap generator dengan karakteristik modul CM. [ISI: temuan utama, mis. karakteristik yang paling kuat berasosiasi]. Karena MuTAP hanya dijalankan pada MT *suite*, analisis ini mencakup Pynguin, CodaMOSA, dan CoverUp.

**TABEL VIII. Korelasi Spearman parsial (kendali LOC) antara karakteristik modul dan keunggulan branch coverage per modul (CM suite, B1)**

| Perbandingan | Karakteristik | ρ parsial | p (Holm) |
|---|---|---|---|
| CoverUp vs Pynguin | Cyclomatic complexity | – | – |
| CoverUp vs Pynguin | Dependensi eksternal | – | – |
| CoverUp vs Pynguin | Densitas anotasi tipe | −0.91† | <0.001† |
| CodaMOSA vs Pynguin | Cyclomatic complexity | – | – |
| CodaMOSA vs Pynguin | Dependensi eksternal | – | – |
| CodaMOSA vs Pynguin | Densitas anotasi tipe | – | – |
| CoverUp vs CodaMOSA | Cyclomatic complexity | – | – |
| CoverUp vs CodaMOSA | Dependensi eksternal | – | – |
| CoverUp vs CodaMOSA | Densitas anotasi tipe | – | – |

*n = [ISI] modul CM (minimal 40). Keunggulan = selisih median branch coverage kedua generator pada suatu modul, dalam poin persentase. ρ parsial mengendalikan ukuran modul (LOC); p-value dikoreksi Holm atas sembilan uji. † Nilai dummy.*

**CATATAN — hapus sebelum submit: TABEL VIII — arti kolom dan cara membaca**

**Letak:** Subbab IV-C (RQ3). **Sumber data:** selisih median BC per modul (S4) + karakteristik modul yang dihitung di S1. **Analisis:** 6 (korelasi Spearman parsial [28], dikontrol terhadap LOC) dengan koreksi Holm [26].

- **Perbandingan:** pasangan tool. Untuk setiap modul dihitung selisih median BC (tool pertama dikurangi tool kedua). Selisih dipakai, bukan Â12, karena Â12 cenderung menumpuk di 1,0 bila satu tool selalu menang, sehingga korelasinya kehilangan variasi.
- **Karakteristik:** cyclomatic complexity (jumlah jalur percabangan), jumlah dependensi eksternal, dan densitas anotasi tipe (proporsi parameter/return yang beranotasi).
- **ρ parsial:** −1 sampai +1, setelah pengaruh ukuran modul (LOC) dikeluarkan. Kontrol LOC diperlukan karena cyclomatic complexity sangat berkorelasi dengan ukuran kode; tanpa itu, yang terukur bisa jadi hanya ukuran. Negatif = makin tinggi karakteristik, makin kecil keunggulan tool pertama. Dengan 40 modul dan 9 uji Holm, $|\rho| \geq 0{,}43$ dapat terdeteksi.
- **p (Holm):** dikoreksi atas 9 uji (3 pasangan × 3 karakteristik).

**Batasan:** korelasi bukan sebab-akibat; tulis "berasosiasi dengan", bukan "menyebabkan". MuTAP tidak tercakup — wajib disebut di Ancaman terhadap Validitas. **Pembeda dari literatur:** TestWeaver [21] sudah

mengelompokkan coverage per LOC dan cyclomatic complexity di CM; studi ini menganalisis KEUNGGULAN RELATIF antar-tool, menambah dependensi eksternal dan anotasi tipe, dan memakai uji statistik.

**Contoh kalimat:** "Keunggulan CoverUp atas Pynguin berasosiasi kuat dan negatif dengan densitas anotasi tipe ($\rho = -0{,}91$), sejalan dengan temuan bahwa ketiadaan informasi tipe menghambat SBST [7]."

**Gambar 5 — placeholder (scatter plot, OPSIONAL)**
Sumbu-x: karakteristik dengan |ρ| terbesar · Sumbu-y: selisih median BC per modul (poin)
Satu titik = satu modul CM · garis horizontal di 0 (tidak ada keunggulan)

Gambar 5. Keunggulan branch coverage per modul terhadap [ISI: karakteristik] pada CM suite.

**CATATAN — hapus sebelum submit: Gambar 5 — fungsi gambar**

Opsional. Dibuang lebih dulu bila halaman tidak cukup; informasinya sudah ada di TABEL VIII.

### *D. Efisiensi dan Biaya*

TABEL IX melaporkan biaya pembangkitan per unit. [ISI: perbandingan biaya, mis. generator termahal dan selisihnya terhadap peningkatan efektivitas].

**TABEL IX. Biaya pembangkitan per unit (median)**

| Suite | Tool | BB | Waktu (s) | Panggilan API | Token (ribu) | Biaya (USD) |
|---|---|---|---|---|---|---|
| MT | Pynguin | – | – | 0 | 0 | 0 |
| MT | CoverUp | B1 | 23.5† | 4† | 12.1† | 0.04† |
| MT | CodaMOSA, CoverUp, MuTAP | B1, B2 | – | – | – | – |
| CM | Pynguin, CodaMOSA, CoverUp | –, B1, B2 | – | – | – | – |

*Waktu adalah wall-clock time pembangkitan tanpa waktu tunggu rate limit, yang dilaporkan terpisah. Biaya memakai harga penyedia pada saat run ([ISI: tanggal]). Pada tabel akhir, setiap konfigurasi memiliki barisnya sendiri. † Nilai dummy.*

**CATATAN — hapus sebelum submit: TABEL IX — arti kolom dan cara membaca**

**Letak:** Subbab IV-D (pendukung, OPSIONAL). **Sumber data:** log S2 dan llm_proxy (token per panggilan). **Analisis:** 1 (deskriptif); tidak diuji statistik.

- **Waktu:** waktu pembangkitan per fungsi/modul. Waktu menunggu rate limit dipisah agar batas kuota gratis tidak dikira kelambatan tool.
- **Panggilan API / Token:** berapa kali dan seberapa banyak teks yang dikirim ke LLM. Pynguin selalu 0.
- **Biaya:** biaya dalam USD menurut harga penyedia saat run. Untuk backbone gratis, tulis 0 dan sebutkan kuota yang dipakai.

Bila halaman tidak cukup, pindahkan tabel ini ke paket replikasi dan cukup tulis satu kalimat ringkasan di teks.

## V. Pembahasan

[ISI: 3–4 paragraf. Kerangka poin yang wajib dibahas:]

- Apakah peringkat generator pada RQ1 bertahan pada kedua *backbone* atau berubah mengikuti *backbone* (menghubungkan RQ1 dan RQ2).
- Ketidaksesuaian antara *coverage* dan *mutation score*: sebuah generator dapat unggul pada satu metrik tetapi tertinggal pada metrik lainnya.
- Bagaimana hasil ini dibandingkan dengan hasil CoverUp [10] dan TestWeaver [21] dengan *backbone* masing-masing.
- Panduan praktis: generator mana yang dipakai untuk jenis kode apa (dari RQ3) dan dengan biaya berapa (TABEL IX).

**CATATAN — hapus sebelum submit: Bab V — fungsi**

Hasil menyajikan angka; Pembahasan menjelaskan ARTINYA. Jangan mengulang angka tabel satu per satu. Hubungkan temuan dengan celah di Pendahuluan: (1) satu backbone tidak cukup, (2) coverage saja tidak cukup, (3) perlu evaluasi independen.

## VI. Ancaman terhadap Validitas

[ISI: satu paragraf per jenis ancaman. Kerangka poin:]

- **Validitas internal:** adaptasi *prompt* untuk CodaMOSA dan MuTAP sama untuk kedua *backbone* sehingga tidak dapat dipisahkan dari efek *tool*; sifat nondeterministik pencarian dan *sampling* LLM, yang dimitigasi dengan R *run* berulang; CoverUp dihentikan pada anggaran 600 detik walaupun tidak dirancang dengan batas waktu.
- **Validitas konstruk:** efek plafon *coverage* pada MT *suite*; mutan ekuivalen tidak dikeluarkan; *mutation tool* untuk evaluasi berbeda dari *engine* MutPy yang dipakai MuTAP secara internal.
- **Validitas eksternal:** MuTAP hanya dijalankan pada MT *suite* sehingga tidak tercakup dalam RQ3; CM *suite* diambil sampelnya, bukan seluruhnya; hanya Python; dua *backbone*.
- **Validitas kesimpulan:** perbandingan berganda, ditangani dengan metode Holm; daya uji statistik bergantung pada R.
- **Kontaminasi data:** HumanEval dan proyek-proyek CM bersifat publik sehingga mungkin termasuk data pelatihan *backbone*; kemiripan antara tes yang dibangkitkan dan tes yang sudah ada dilaporkan mengikuti [4], [9].

**CATATAN — hapus sebelum submit: Bab VI — fungsi**

Bagian ini mengakui batasan sebelum reviewer menemukannya. Setiap ancaman ditulis bersama mitigasinya (misalnya "nondeterminism → R run + uji statistik"). Ancaman tanpa mitigasi cukup diakui terus terang.

## VII. Kesimpulan

[ISI: 1 paragraf, ±120 kata: ringkasan jawaban RQ1–RQ3 dalam satu kalimat masing-masing, kontribusi utama, dan rencana penelitian lanjutan. Jangan memasukkan angka baru yang tidak ada di Hasil.]

# Lampiran A. Penjelasan metrik evaluasi dan analisis

Semua penjelasan memakai satu contoh kode yang sama:

```
def diskon(harga, member):
    if member:                  # cabang 1: True / False
        harga = harga * 0.9
    if harga > 100:             # cabang 2: True / False
        harga = harga - 5
    return harga

def test_diskon():
    assert diskon(200, True) == 175   # 200 × 0,9 = 180 → 180 > 100 → 175
```

## *A.1 Metrik evaluasi (tahap S4)*

**Tabel A-1. Metrik evaluasi**

| Metrik | Mengukur apa | Contoh pada diskon() | Dihitung dari | Sumber |
|---|---|---|---|---|
| Line coverage | Persentase baris kode yang dijalankan tes | Kelima baris dijalankan → 5/5 = 100% | Tes valid | [10] |
| Branch coverage | Persentase arah True/False dari setiap if yang dilalui tes | Hanya member=True dan harga>100=True → 2/4 = 50% | Tes valid | [10] |
| Mutation score | Kemampuan tes mendeteksi kesalahan buatan (mutan) | 0.9→0.8: terbunuh; >→>=: bertahan → 1/2 = 50% | Tes valid, mutan sama untuk semua tool | [25] |
| Raw validity | Persentase tes usulan LLM yang lulus pada kode asli sebelum diperbaiki tool (validitas tes, RQ1) | LLM mengusulkan 10 tes, 6 lulus → 60%; tes "== 180" gagal karena salah | Usulan mentah LLM (log llm_proxy) | [9], [11] |
| Pass rate suite akhir | Persentase tes di suite akhir yang lulus (pemeriksaan kewajaran) | CoverUp membuang 3 tes gagal → 7/7 = 100% | Suite akhir | [10] |
| Flaky count | Tes yang hasilnya berubah-ubah tanpa perubahan kode | Tes yang memakai waktu sekarang atau angka acak | Tes yang lulus, diulang k kali | [30] |
| Waktu, API, token | Biaya menghasilkan tes | Detik per unit; jumlah panggilan LLM; jumlah teks | Setiap run | – |

*Line coverage 100% tetapi branch coverage 50% menunjukkan kenapa keduanya dilaporkan. Tes tanpa assert bisa mencapai coverage 100% tetapi mutation score 0%.*

## *A.2 Analisis statistik (tahap S5)*

**Tabel A-2. Analisis statistik**

| No | Analisis | Pertanyaan yang dijawab | Contoh singkat | RQ | Sumber |
|---|---|---|---|---|---|
| 1 | Median + boxplot | Seperti apa gambaran dan sebaran hasil? | 70, 82, 85, 86, 90 → median 85; satu run gagal tidak merusak median | Semua | [23] |
| 2 | Wilcoxon signed-rank | Apakah perbedaan dua tool nyata atau kebetulan? | Selisih per fungsi +10, +3, +5, −2, +15 → konsisten positif → p kecil | RQ1 | [27] |
| 3 | Â12 (Vargha–Delaney) | Seberapa besar perbedaannya? | A = [80, 82, 85], B = [70, 75, 90] → A menang 6 dari 9 pasangan → 0,67 | RQ1 | [24] |
| 4 | Koreksi Holm | Apakah tetap nyata setelah banyak uji? | p = 0,01; 0,03; 0,04 → ×3, ×2, ×1 → 0,03; 0,06; 0,06 → hanya satu yang bertahan | RQ1, RQ3 | [26] |
| 5 | Mixed-effects model | Perbedaan berasal dari algoritma, backbone, atau kombinasinya? | Ganti ke B2: CodaMOSA −1,0; MuTAP −1,0 − 13,1 = −14,1 poin | RQ2 | [29] |
| 6 | Spearman parsial (kontrol LOC) | Jenis kode apa yang cocok untuk tiap tool? | Anotasi tipe makin sedikit → keunggulan CoverUp atas Pynguin makin besar (ρ negatif), terlepas dari ukuran modul | RQ3 | [28] |

*Pemilihan uji non-parametrik dan ukuran efek Â12 untuk algoritma acak mengikuti pedoman [23]. Contoh angka adalah ilustrasi, bukan hasil.*

# Lampiran B. Peta RQ → metrik → analisis → tabel/gambar → subbab

**Tabel B-1. Peta keterkaitan**

| RQ | Suite | Metrik (S4) | Analisis (S5) | Tabel / Gambar | Subbab |
|---|---|---|---|---|---|
| RQ1 | MT (4 tool), CM (3 tool) | RV, flaky, LC, BC, MS | 1, 2, 3, 4 | TABEL IV, TABEL V, Gambar 3 | IV-A |
| RQ2 | MT (3 tool LLM), CM (2 tool LLM) | MS (MT), BC (CM), RV; adaptasi prompt hanya dilaporkan | 1, 5 | TABEL VI, TABEL VII, Gambar 4 | IV-B |
| RQ3 | CM saja (3 tool) | Selisih median BC per modul + karakteristik modul + LOC | 6, 4 | TABEL VIII, Gambar 5 (opsional) | IV-C |
| Pendukung | MT, CM | Waktu, API, token, biaya | 1 | TABEL IX (opsional) | IV-D |

*Nomor analisis mengacu pada Tabel A-2.*

# Lampiran C. Ringkasan tabel dan gambar serta ruang halaman

**Tabel C-1. Daftar tabel dan gambar Bab IV**

| Item | Isi | Ukuran | Status |
|---|---|---|---|
| TABEL IV | Efektivitas per tool × backbone | 1 kolom, 12 baris | Wajib |
| TABEL V | Perbandingan berpasangan (B1) | 1 kolom, 12 baris | Wajib |
| Gambar 3 | Boxplot MT: coverage vs MS | 1 kolom | Wajib |
| TABEL VI | Efek backbone + jenis adaptasi | 1 kolom, 5 baris | Wajib |
| TABEL VII | Mixed-effects model | 1 kolom, 8 baris | Wajib |
| Gambar 4 | Interaction plot | 1 kolom | Wajib |
| TABEL VIII | Spearman (CM) | 1 kolom, 9 baris | Wajib |
| TABEL IX | Efisiensi dan biaya | 1 kolom, 12 baris | Opsional |
| Gambar 5 | Scatter RQ3 | 1 kolom | Opsional |
| Paket replikasi | Perbandingan B2 dan metrik lain; run gagal per kategori error; daftar adaptasi prompt lengkap | – | Di luar paper |

*Perkiraan: 5 tabel + 2 gambar wajib ≈ 1,5 halaman IEEE; dengan item opsional ≈ 2 halaman.*

**CATATAN — hapus sebelum submit: Peringatan ruang halaman**

Draf Bab I–III saat ini sekitar 10 halaman satu kolom. Untuk batas conference 6 halaman dua kolom, ruang Hasil tidak akan cukup. Yang dipangkas adalah Metodologi (Tabel II ke paket replikasi, Subbab III-B dipadatkan), bukan Hasil.

# Referensi baru untuk Bab IV (melanjutkan [23]–[26] Metodologi)


[23] A. Arcuri and L. Briand, "A practical guide for using statistical tests to assess randomized algorithms in software engineering," in *Proc. 33rd Int. Conf. Softw. Eng. (ICSE)*, 2011, pp. 1–10, doi: 10.1145/1985793.1985795.

[24] A. Vargha and H. D. Delaney, "A critique and improvement of the CL common language effect size statistics of McGraw and Wong," *J. Educ. Behav. Stat.*, vol. 25, no. 2, pp. 101–132, 2000, doi: 10.3102/10769986025002101.

[25] Y. Jia and M. Harman, "An analysis and survey of the development of mutation testing," *IEEE Trans. Softw. Eng.*, vol. 37, no. 5, pp. 649–678, 2011, doi: 10.1109/TSE.2010.62.

[26] S. Holm, "A simple sequentially rejective multiple test procedure," *Scand. J. Statist.*, vol. 6, no. 2, pp. 65–70, 1979.

[27] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bull.*, vol. 1, no. 6, pp. 80–83, 1945, doi: 10.2307/3001968.

[28] C. Spearman, "The proof and measurement of association between two things," *Amer. J. Psychol.*, vol. 15, no. 1, pp. 72–101, 1904, doi: 10.2307/1412159.

[29] D. Bates, M. Mächler, B. Bolker, and S. Walker, "Fitting linear mixed-effects models using lme4," *J. Stat. Softw.*, vol. 67, no. 1, pp. 1–48, 2015, doi: 10.18637/jss.v067.i01.

[30] Q. Luo, F. Hariri, L. Eloussi, and D. Marinov, "An empirical analysis of flaky tests," in *Proc. 22nd ACM SIGSOFT Int. Symp. Found. Softw. Eng. (FSE)*, 2014, pp. 643–653, doi: 10.1145/2635868.2635920.

**CATATAN — hapus sebelum submit: Catatan referensi**

[7], [10], [12], dan [21] yang disebut di bab ini sudah ada di Daftar Pustaka Bab I–II. [23]–[26] sebelumnya bertanda [PERLU DICEK]; data bibliografinya kini sudah dicocokkan (13 Oktober 2026) dan tanda itu bisa dihapus di Methodology. [27]–[30] adalah referensi baru: tambahkan ke Daftar Pustaka utama.

Wilcoxon [27] menggantikan peran Mann–Whitney di Metodologi III-G; perbarui juga Tabel III dan teks III-G.